Datasheet

为大语言模型添加知识

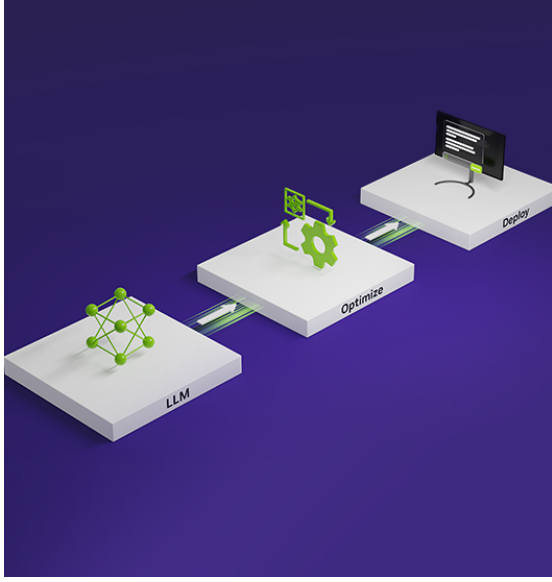

课程概述

大语言模型 (LLMs) 功能强大，但它们的知识通常是通用的，可能缺乏企业应用所需的特定、最新或专业信息。《为大语言模型添加知识》课程提供了一个全面、实践的指南，涵盖增强和定制 LLM 的核心技术。

本课程将带您从原始数据出发，走完构建一个经过优化的微调模型的完整流程。首先，您将学习如何使用 NVIDIA NeMo Curator 筛选高质量数据集并生成合成数据。接着，深入掌握模型评估过程，使用基准测试、LLM-as-a-judge 和 NeMo Evaluator 严格评估模型性能。在打下坚实评估基础之后，您将学习一系列强大的定制技术，包括使用持续预训练注入新知识、通过监督微调教授新技能，以及使用直接偏好优化 (DPO) 使模型行为更符合人类偏好。

最后，您将学习如何通过量化、剪枝和知识蒸馏等优化技术 (基于 TensorRT-LLM 和 NeMo 框架) 让您的定制模型在实际部署中高效运行。课程最终将通过一次实践评估收尾，您将在其中运用所学内容将 LLM 调整为特定的对话风格，全面掌握为任何应用场景定制模型的能力。

学习目标

参加本次培训，您将学到：

- 使用 NVIDIA NeMo Curator 筛选高质量数据集并生成合成数据
- 结合基准测试 (如 MMLU)、LLM-as-a-judge 和 NeMo Evaluator 严格评估模型性能
- 通过持续预训练 (CPT) 为 LLM 注入特定领域的新知识
- 通过监督微调 (SFT) 让 LLM 学习新技能并完成特定任务
- 使用直接偏好优化 (DPO) 使模型在风格、语气和安全性方面更贴近人类偏好
- 通过 TensorRT-LLM 和 NeMo 进行量化、剪枝与知识蒸馏，压缩并优化 LLM 以实现高效部署
- 掌握端到端的模型定制工作流，用于解决真实世界的问题

课程概要	
课程时长	8 小时，课后 6 个月内可以继续访问课件和实验 (实验资源用量有限额)
课程模式	讲师授课，每位学员使用完全配置的云端实验环境进行实战练习
预备知识	> 熟悉 Python 编程与 Jupyter notebook > 了解大语言模型及其应用 > 具备深度学习与神经网络的基本概念
使用的工具、库和框架	Python，NVIDIA NeMo，NVIDIA TensorRT-LLM，Docker，MLflow

课程概要	
课程涵盖主题与技术	为帮助学习和演示如何为 LLM 增加知识并进行企业级定制，本课程将涵盖以下主题与技术： > 数据筛选与合成数据生成 > 高级 LLM 评估技术 (包括 LLM-as-a-Judge 和 ELO) > 持续预训练 (CPT) 用于知识注入 > 监督微调 (SFT) 用于技能习得 > 直接偏好优化 (DPO) 用于行为对齐 > 模型优化：量化、剪枝与知识蒸馏 > NVIDIA NeMo 框架、NeMo Curator、NeMo Evaluator 与 NeMo-RL > TensorRT-LLM 高性能推理优化
课程评测方式	运用所学内容将 LLM 调整为特定的对话风格，掌握根据场景定制模型的能力
培训证书	成功完成本课程和测试后，学员将获得 NVIDIA 培训证书，证明在相关领域的技能，为职业发展提供证明
课程语言	中文
学习此课程的硬件要求	您需要一台能够上网的笔记本电脑或台式机，且能够运行最新版 Chrome 或 Firefox 浏览器；我们为您提供在云端实验环境的专用访问权限
课程价格	微信添加 DLI 小助手 (微信号 NVIDIALearn)，沟通培训需求

课程大纲	
课程介绍 (15 分钟)	> 讲师介绍 > 登录 DLI 学习平台
数据筛选与合成数据生成 (60分钟)	> 使用 NVIDIA NeMo Curator 构建大规模高质量数据集 > 执行关键数据筛选任务：文本清洗、过滤和 PII 去除 > 生成高质量的问答对数据，用于构建稳健的 SFT 数据集 > 理解数据质量在 LLM 开发生命周期中的重要性
大语言模型评估 (75 分钟)	> 从简单的“目测”到系统的量化方法，全面了解多种评估技术 > 使用 MMLU 等行业标准基准测试评估模型 > 实现 LLM-as-a-judge 进行更细致的自动化评估 > 使用 NeMo Evaluator 微服务比较 zero-shot 与 few-shot (上下文学习) 表现 > 使用 MLflow 跟踪与可视化评估实验
休息 (60 分钟)	
LLM 定制 (120 分钟)	> 深入三大定制技术：CPT、SFT 和 DPO > 通过 CPT 教会模型一个特定领域的新知识 > 使用 SFT 教会模型新技能，比如用另一种语言解数学题 > 利用 DPO 将模型对话风格调整为人类偏好 (如正式与非正式语气、特定方言等) > 通过 NeMo 框架动手实践完成定制任务
为部署优化 LLM (120 分钟)	> 学习如何压缩和加速 LLM，以实现高效推理 > 使用 TensorRT-LLM 应用后训练量化 (PTQ)，减少模型尺寸与内存占用，重点使用 FP8 格式 > 通过层级剪枝 (Depth Pruning) 删除整个层以减小模型规模 > 使用知识蒸馏技术，训练小型“学生”模型模仿大型“教师”模型，以恢复剪枝带来的性能损失 > 权衡每种优化技术在性能与准确率上的利弊

课程大纲	
评估测试和总结 (30 分钟)	> 在实践编程任务中运用所学知识 > 使用 DPO 将 Llama 3.1 8B 模型调整为特定对话风格 (如莎士比亚式英文) > 展示您准备偏好数据集、使用 NeMo-RL 运行对齐任务并评估最终模型的能力 > 成功完成评估后可获得 NVIDIA 培训证书
下一步	学习更多 DLI 相关课程： > 使用大语言模型 (LLM) 构建 AI 智能体 > 使用 NVIDIA NIM 大规模部署 RAG 工作流 > 高效定制大语言模型 (LLM) > 构建基于大语言模型 (LLM) 的应用 > 利用提示工程构建大语言模型 (LLM) 应用 > 使用多模态模型构建 AI 智能体 > 构建大语言模型 RAG 智能体 > 构建基于扩散模型的生成式 AI 应用

为何选择 NVIDIA 深度学习培训中心 (DLI) 的实战培训?

> 学习 NVIDIA 与技术专家和行业领导者合作开发的课程，获取全球同步、技术领先和现实可用的专业开发技能和经验。

> 学习使用行业通用、标准的软件、工具和框架进行端到端的应用开发，能够在广泛的行业中构建基于深度学习、加速计算、图形与仿真和数据科学的应用。

> 系统化地学习理论，并使用云端完全配置的实验环境同步边练，高效提升实战开发能力。

> 获得 NVIDIA 全球开发者培训证书，加持专业培训认证，助力职业发展。

准备好开始学习了吗?

查询更多 DLI 课程，请访问 nvidia.cn/training

如有疑问，请通过微信联系 DLI 小助手 (微信号 NVIDIALearn)。

© 2025 NVIDIA Corporation。保留所有权利。NVIDIA、NVIDIA 徽标、Clara、CUDA、DGX、DGX SuperPOD、Index 和Triton 均为 NVIDIA Corporation 在美国和其他国家 / 地区的商标和 / 或注册商标。其他公司和产品名称可能是其各自关联公司的商标。其他所有商标均为其各自所有者的财产。4077650。2025 年 7 月